

Intelligente Industrieroboter

Implementierung eines Clusteringbasierten Verfahrens zur Visualisierung von Volumenmodellen

written by

Lukas Diewald

At the Department of Computer Science
Institute for Anthropomatics and Robotics (IAR) -
Intelligent Process Control and Robotics (IPR)

First reviewer: Prof. Dr.-Ing. habil. Björn Hein
Second reviewer: Prof. B

August 8, 2018

Todo list

| | |
|---|----|
| ■ Rewrite this seciton | 1 |
| ■ besser formulieren | 2 |
| ■ übersicht zu oft | 2 |
| ■ besser schreiben | 6 |
| ■ altes paper auch einbinden | 6 |
| ■ richtig bild zitieren u. evtl kleiner | 8 |
| Figure: Please add some figures | 10 |

Executive Summary

English abstract.

Keywords: *Keywords, of, my, Thesis*

Contents

| | |
|---|-----------|
| 1. Introduction | 1 |
| 2. State of the art | 2 |
| 2.1. Eindimensionale Verfahren | 2 |
| 2.2. Zweidimensionale Verfahren | 2 |
| 2.3. Räumlichbasierte Verfahren | 3 |
| 2.4. Machinelearning Verfahren | 4 |
| 2.5. Bildbasierte Verfahren | 5 |
| 2.6. Clusteringbasierte Verfahren | 5 |
| 3. Methods | 8 |
| 4. Concept | 9 |
| 5. ImplementationImplementation | 10 |
| 6. Results | 11 |
| 7. Discussion | 12 |
| 8. Conclusion | 13 |
| Bibliography | 14 |
| Appendix | 16 |
| A. First Appendix Section | 16 |

1. Introduction

As an useful aid in all scientific work following book is recommended: [?]

-transferfunktionen was ist das? -ventrikelsystem -medizinische bildverarbeitung -ct daten

Rewrite
this
section

2. State of the art

Das Gebiet der Transferfunktionen ist bereits weit erforscht und es existieren viele unterschiedliche Methoden und Herangehensweisen um medizinische Daten abhängig von verschiedenen Problemstellungen passend darzustellen.

Dabei kann man einerseits zwischen dem Level an Automation eines Systems unterscheiden. Hierbei gibts es vollautomatische Verfahren, bei denen keine Interaktion mit den Benutzer von Nöten ist, semiautomatische Verfahren bei denen der Benutzer noch an gewissen Stellschrauben drehen kann um das Ergebnis zu beeinflussen und manuelle Verfahren, bei denen der Anwender mehr oder minder auf sich alleine gestellt ist. Transferfunktionene unterscheiden sich weiterhin in ihrer Dimensionalität. Es gibt ein- zwei- und allgemein-mehrdimensionale Transferfunktionen. Desweiteren sind die Grundlagen auf denen die Berechnungen ruhen teils völlig verschieden. Manche Verfahren basieren auf den Intensitätswerten oder deren Änderung im gegebenen Volumen, andere auf der Größe der Features die für den Nutzer von interesse sind. Wieder andere sind Bildbasiert oder wenden Machinelearning an um zum gewünschten Ziel zu gelangen.

besser
for-
mulieren

In diesem Abschnitt wird ein Überblick über die unterschiedlichen Vorgehensweisen von Transferfunktionen gegeben. Dabei werden diese im Folgenden für die Übersicht in die Kategorien Eindimensionale, Zweidimensionale, Räumlichbasierte, Machinelearning, Bildbasierte, Clusteringbasierte Verfahren geteilt.

Dabei ist jedoch zu beachten, dass die Kategorien lediglich der Übersicht diese Abschnitts dienen. Die Kategorien hätten anders gewählt werden können. Desweiteren können manche Verfahren nicht eindeutig in die hier genannte Unterteilung eingeteilt werden, da sie mehrere Klassen auf sie zutreffen.

übersicht
zu oft

2.1. Eindimensionale Verfahren

Die einfachste Form der Transferfunktionrm, sind die eindimensionalen Transferfunktionen. In diesen, wird nur der Intensitätswert der Voxel in Betracht gezogen. Abgesehen von den niedrigen Berechnungszeiten, sind diese jedoch aus mehreren Gründen suboptimal. Medizinischen Daten werden gemessen und haben deshalb meist ein Rauschen, was die genaue Darstellung erschwert. Weiterhin sind die Intensitätswerte verschiedener Bereiche nah beieinander oder gar gleich und damit sind eindimensionale Transferfunktionen unpraktisch um verschiedene Materialien kenntlich zu machen. Trotzdem sind eindimensionale Transferfunktionen weit verbreitet und werden oft benutzt.

2.2. Zweidimensionale Verfahren

Die Arbeit von Shouren Lan [1] befasst sich mit der Verbesserung von 2D Transferfunktionen die auf Skalarwerten und Gradienten(SG-TF) basieren. Genauer geht es darum das Problem vom Auftauchen von Überlappungen von Bereichen die nicht zusammen gehören zu vermeiden.

Dabei wird im Paper zwischen 3 verschiedenen Arten von Strukturen unterschieden:

- (i) Strukturen die keine andere Struktur berühren
- (ii) Strukturen die keine andere Struktur berühren, jedoch nah an einer andern liegen

- (iii) Strukturen die andere Strukturen berühren

Wenn der Benutzer eine Region ausgewählt hat, werden zunächst alle Strukturen in dem Bereich klassifiziert und kleine Fragmente entfernt. Durch verschiedene Algorithmen werden Strukturen der Klassen (ii) durch Erosion, Dilatation, Aufteilen und neu zusammenfügen von einander getrennt. Strukturen der Klasse (iii) werden durch eine weitere niedrig dimensionale Transferfunktion getrennt. Anschließend werden durch das Aufteilen entstehende Löcher mit Hilfe von Dilatation gestopft. Als letztes wird durch eine Transferfunktion den Strukturen entsprechende Farben und Intensitäten zugewiesen.

2.3. Räumlichbasierte Verfahren

In der Arbeit von Wesarg und Kirschner [2, 3] wird das "Structure-Size-Enhanced Histogram" vorgestellt.

Dafür muss für jeden Voxel die "structure size estimators" berechnet werden. Dies geschieht, indem betrachtet wird, wie viele Schritte in die Richtung der 26 Nachbarn des Voxel gemacht werden kann. Ein Schritt kann gemacht werden, wenn der Intensitätswert des erreichten Voxels nicht mehr als ein gegebener Parameter abweicht. Die Schrittweiter startet mit einem Voxel und verdoppelt sich mit jedem gemachten Schritt bis hin zur Hälfte der Größe des gegebenen Volumens. Für ein besseres Ergebnis wird nur der kleinere Wert von zwei entgegengesetzten Richtungen gespeichert. Die Akkumulation aller Werte ergibt die Größe der Struktur. Aus diesem und dem Intensitätswert wird ein zweidimensionales Histogramm erstellt.

Es gibt diverse Regiongrowingverfahren um Strukturen von Interesse hervorzuheben.

Beispielsweise wird im Paper von Huang [4] ein solches Regiongrowingverfahren vorgestellt. Der Benutzer kann einen Punkt von Interesse im Volumen wählen, den sogenannten "seed". Es werden alle 26 Nachbarn des "seeds" besucht und anhand einer Kostenfunktion, die den entsprechenden Wert des besuchten Voxels und des Seedvoxels vergleicht, entschieden ob sie zu der Region dazugehören oder nicht. Sind sie Teil der Struktur werden auch ihre Nachbarn besucht und alle passenden Voxel zu der Region hinzugefügt. Dieser Vorgang wiederholt sich so lange bis alle Voxel gefunden wurden, oder ein anderes internes Abbruchkriterium erfüllt wurde. Es stehen dem Anwender 3 verschiedene Kostenfunktionen bereit. Die erste Funktion bezieht sich auf die Intensitätswerte der Voxel, die Zweite auf die Länge der jeweiligen Gradienten und bei der Dritten werden die Gewichte der Voxel verglichen, die vorher vom Benutzer definiert werden müssen. In einem Nachbearbeitungsschritt ist es anschließend noch möglich unpassende Elemente zu entfernen, wenn beispielsweise eine ganze weitere Struktur auch visualisiert wird, da sie über eine kleine Brücke von ein bis zwei Voxeln mit der eigentlich gesuchten Struktur verbunden ist.

Da das Regiongrowing sehr zeitaufwändig ist, kann der Anwender auswählen, dass er zunächst nur einen gewissen Teil der Region sich errechnen lässt.

Correa und Ma zeigen in ihrer Arbeit [5] einen Ansatz, der auf der relativen Größe der zu visualisierenden Features basiert.

Dazu benutzen sie den sogenannten "scale-space", welcher für das Volumen berechnet wird, um anschließend eine auf Größe basierende Transferfunktion anzuwenden. Diese mappt Farbe und Okklusion zu den entsprechenden Größen der Features des Volumens. In einem weiteren Paper [6] beschreiben die beiden Forscher ein Verfahren, dass auf der

Okklusion der Voxel basiert.

Dafür betrachten sie die Umgebung einzelner Voxel und berechnen abhängig davon, die Okklusion. Die Ergebnisse werden in einem zweidimensionalen Histogramm gespeichert in Kombination mit den Intensitätswerten der Voxel. Durch die Umgebungsokklusion der Voxel ist es leicht mit einer auf dem Histogramm basierenden Transferfunktion unterschiedliche Materialien mit gleichen Intensitätswerten zu unterscheiden.

Eine weitere Arbeit [7] von Correa und Ma beschäftigt sich mit Transferfunktionen abhängig von der Sichtbarkeit einzelner Voxel.

Die Sichtbarkeit jedes Voxels wird abhängig vom Sichtpunkt auf das Volumen berechnet, indem die Opazität vom Standpunkt der Kamera bis hin zum Voxel akkumuliert wird. Anschließend wird ein Histogramm über die Sichtbarkeitswerte erstellt. Auf diesem kann der Benutzer eine Transferfunktion erstellen, bei der er ein direktes Feedback über die Darstellung erhält. Um das gewünschte Ergebnis zu erhalten, wäre jedoch ein sehr genaues Einstellen dieser Funktion von Nöten, was der User nur schwer umsetzen kann. Deshalb wird eine Energiefunktion erstellt, die es zu minimieren gilt. Damit wird das Problem wie bei [8] zu einem Optimierungsproblem, welches mithilfe von progressiver Suche gelöst werden kann. Der Anwender muss dafür lediglich eine Opazitätsfunktion angeben, die seine gewünschten Visualisierungsziele beschreibt. Hierbei kann er auch aus vorgefertigten Funktionen wählen.

Diese Histogramme des vorangegangenen Papers wurde von Correa und Ma in einer erweiterten Arbeit [9] nochmals verbessert. Sie führten multidimensionale Sichtbarkeitshistogramme, die beispielsweise auch die Gradientenlänge in Betracht ziehen. Desweiteren stellen sie zwei Methoden vor zur Berechnung von Sichtpunkt unabhängigen Sichtbarkeitshistogrammen. Zum einen ein Omni-direktionales Sichtbarkeitshistogramm, bei dem die Sichtbarkeit von allen möglich Sichtpunkten berechnet wird. Und ein Radales Sichtbarkeitshistogramm, bei dem radiale Strahlen verwendet werden. Dazu wird das kartesische in ein sphärisches Koordinatensystem umgerechnet.

Im Vergleich zu Huan [4] benutzt Chen in seiner Arbeit [10] nicht nur ein seedbasiertes Verfahren, sondern fügt noch ein sketchbasiertes Verfahren davor ein.

Anfangs wählt der Anwender eine Reihe an Intensitätswerten im Histogramm, die für ihn interessant sind. Danach kann er direkt im Volumen eine Region von Interesse einzeichnen und markieren. Das Programm schneidet im Anschluss, alle Teile des Volumens außerhalb der gewählten Region weg. Jetzt kann der Nutzer wie im vorrig vorgestellten Verfahren seinen "seed" setzen.

Dies erleichtert dem Benutzer die Anwendung, da er schneller zu seinem Punkt von Interesse gelangt ohne vorher durch diverse Querschnittsbilder iterieren zu müssen. Desweiteren ist es Zeitsparend für den User, falls er sich nicht genau mit dem Datensatz und der zu Visualisierenden Region auskennt.

2.4. Machinelearning Verfahren

Die Arbeit von Tzeng [11] benutzt Machinelearning um interessante Strukturen darzustellen. Hierbei wird ein Neuronales Netz und eine Support Vector Machine benutzt.

Als Input für das Verfahren kann der Benutzer im Volumen mit zwei verschiedenen Farben Regionen anmalen und damit markieren. Mit der einen Farbe markiert der Nutzer die Stellen von Interesse, die er hervorgehoben haben möchte, mit der anderen Farbe Stellen, die ihn explizit nicht interessieren. Das Programm nimmt im Anschluss die Intensitätswerte, Länge der Gradienten und Intensitätswerte der Nachbarn aller markierter

Voxel als Input um eine sinnvolle Segmentierung zu finden. Das Ergebnis wird dem Anwender in Form einer farbigen Darstellung gezeigt, bei der er abhängig von der Farbe der Regionen sieht wie ähnlich sie den angemalten Voxeln sind. Gefällt dem Benutzer das Ergebnis noch nicht, so kann er durch weiteres einfärben von Regionen das Ergebnis verbessern bis das gewünschte Resultat erreicht wird.

Soundararajan stellt ein Verfahren vor [12], bei dem der Anwender auch direkt im Volumen markieren kann, welche Gebiete für ihn von Interesse sind.

Dabei wird überwacht maschinelles Lernen angewendet, um aus dieser Eingabe eine probabilistische Übertragungsfunktion abzuleiten. Dabei ist es wichtig, dass das ausgewählte Machinelearningverfahren wie gesagt eine probabilistische Klassifikation erlaubt. Desweiteren muss es nicht nur zwischen zwei verschiedenen Klassen unterscheiden können sondern multiple Klassen unterstützen.

In dem Paper wird das Verfahren mit fünf verschiedenen Machinelearningverfahren getestet und erklärt wie weit mit diesen das gegebene Verfahren umsetzbar ist. Es wurden "Gaussian Naive Bayes", "k Nearest Neighbor", "Support Vector Machines", "Random Forests" und "Neural Networks" getestet.

2.5. Bildbasierte Verfahren

Eine weitere Art Transferfunktionen anzuwenden, sind Verfahren, die auf einem Bild basieren. Hier hat der Benutzer die Möglichkeit, mit dem Programm zu interagieren. Dies ist für einen unerfahrenen User intuitiver und er kann durch ausprobieren ein gewünschtes Ergebnis erzielen.

Fang stellt in seinem Paper [13] ein Verfahren vor, bei dem die Transferfunktion eine Abfolge von verschiedenen 3D Bildverarbeitungsverfahren ist, deren Parameter vom Benutzer angepasst werden können.

Es gibt auch Methoden, bei denen ein Hilfswerkzeug zum Einsatz kommt. Zum Beispiel kann der Benutzer im Paper von Reiting: [14] sich gezielt Bereiche des Volumens hervorheben lassen, indem er sie mit einem Stift auswählt. Hierbei wird die Intensität des ausgewählten Punktes als auch der räumliche Abstand zum Stift in Betracht gezogen.

Wu und Qu stellen in ihrer Arbeit [8] ein intuitives Verfahren zum verändern von Features von Transferfunktionen vor.

Der Benutzer lädt zwei verschiedene direct volume rendered images (DVRIs) in das Programm. Hierbei wird ihm die jeweilige Visualisierung und Transferfunktion angezeigt. Der User kann entscheiden ob er gewisse Features der beiden DVRIs zu einem verschmelzen, aus beiden mischen oder einzelne löschen möchte. Die Zusammenführung geschieht im Anschluss mithilfe einer Energiefunktion, die die Ähnlichkeit zweier Bilder beschreibt. Das Zusammenführen wird somit zu einem Optimierungsproblem und zwar dem minimieren der Energiefunktion. Dieses Problem kann mithilfe eines stochastischen Suchalgorithmus gelöst werden. Der Anwender bekommt am Ende eine Visualisierung mit allen gewünschten Features.

2.6. Clusteringbasierte Verfahren

Sereda baut seine Arbeit [15] auf den von Serlie [16] vorgestellten LH-Histogrammen auf und zeigt wie man mit ihnen Objekte klassifizieren kann.

Die Berechnung eines LH-Histogramms ist eine Methode zur Erkennung von Kanten, unter der Verwendung von Low- und High-Werten. Dabei werden die Voxel in zwei verschiedenen Kategorien eingeteilt. Es gibt Voxel, die innerhalb eines Materials liegen und welche, die an der Grenze zweier Materialien liegen. Ist ein Voxel innerhalb, so sind seine LH-Werte gleich. Grenzvoxel hingegen haben unterschiedliche Low- und High-Werte, wobei diese die Intensitätswerte der beiden Materialien, zwischen denen die Grenze verläuft, beschreiben.

Bei der Berechnung des Histogramms wird als erstes getestet, ob der betrachtete Voxel an einer Grenze liegt. Ein Punkt liegt innerhalb eines Materials, wenn die Länge des Gradienten kleiner als ein gewisses epsilon (bei MRT-Daten) oder gleich null (bei CT-Daten) ist. In diesem Fall wären die Low- und High-Werte der Intensitätswert des Voxels. Ist dies jedoch nicht der Fall, wird in Richtung (für die High-Werte) und entgegengesetzter Richtung (für die Low-Werte) des Gradientens schrittweise integriert. Dies stoppt sobald ein Material gefunden wurde. Dies wird für jeden Punkt im Volumen berechnet und danach aus allen LH-Werten ein Histogramm erstellt.

Zur Visualisierung benutzt Sereda eine dreidimensionale Transferfunktion. Diese nimmt die beiden LH-Werte als auch die Gradientenlänge, aus dem Grund, dass vor allem Voxel nah an der Grenze interessant sind und diese dadurch hervorgehoben werden, als Parameter entgegen.

Weiterhin verwenden die Forscher Regiongrowing um Strukturen zu erkennen. Dabei basiert die Kostenfunktion auf dem LH-Histogramm. Dies ist deutlich besser als Kostenfunktionen, die auf dem Intensitätswert und der Gradientenlänge basieren, da Kanten trotz Überlappungen besser erkannt werden können.

besser
schreiben

In einer späteren Arbeit [17] stellt Sereda ein hierarchisches Clusteringverfahren vor. Hierbei werden in einer Menge von Clustern immer die zwei gemerged, die sich bei dem ausgewählten Vergleichsverfahren am ähnlichsten sind. Es wird eine Kombination aus zwei solcher Vergleichsverfahren vorgestellt. Zum einen wird die räumliche Nähe in Betracht gezogen, bei der gezählt wird, wie viele direkte Nachbarn zwei Cluster besitzen. Zum anderen wird die Nähe im LH-Raum untersucht. Als Startcluster dienen hierbei die Kästchen des LH-Histogramms. Die einzelnen Cluster bekommen für die Visualisierung am Ende einen zufälligen Farbwert zugewiesen.

Das Paper von Binh P. Nguyen [18] stellt ein clusteringbasiertes Verfahren um für den Benutzer interessante Gebiete hervorzuheben.

Zunächst wird in einem Vorverarbeitungsschritt die Gradienten des Volumens berechnet. Hierzu wurde Hong's Methode [19] verwendet. Im Anschluss daran wird anhand der Gradienten die LH-Werte mithilfe von Heuns Methode, eine modifizierte Euler Methode, ermittelt. Hierbei wird desweiteren eine Gewichtung abhängig von der zurückgelegten Strecke bei der Interpolation für den Low- bzw. High-Wert errechnet. Aus den LH-Werten und deren Gewichten wird anschließend ein LH-Histogramm erzeugt.

altes
paper
auch
ein-
binden

Dem Benutzer steht dann ein zwei stufiges und ein drei stufiges Clusteringverfahren zur Auswahl, wobei die ersten beiden Clusteringsschritte die selben sind. Im ersten Clusteringsschritt wird im LH-Raum mithilfe von "Meanshiftclustering" geclustert. Es wird für jeden LH-Wert alle Werte gefunden, die in einem Kreis mit einem Radius von 7% - 9% des maximalen LH-Wertes um den ursprünglichen Punkt liegen. Anschließend wird der neue durchschnittliche Mittelpunkt von allen Punkten im Cluster ermittelt. Der Vorgang wiederholt sich der Mittelpunkt zwischen zwei Iterationen nur minimal ändert. Der komplette Vorgang wird für jeden Punkt im LH-Histogramm wiederholt und in Folge werden

Cluster, deren Mittelpunkt nah beieinander liegen zu einem Cluster gemerged.

Der zweite Clusteringschritt wird auf die Cluster des ersten Schittes angewendet. Hierbei wird auch "Meanshiftclustering" verwendet. Diesmal wird jedoch räumlich, also abhängig von der Position im Volumen, geclustert. Desweiteren werden die Parameter für den Suchradius und Distanz zweier Mittelpunkte damit sie gemerged werden angepasst.


Als Ergebnis der ersten zwei Schritte erhält man Cluster mit Voxeln die ähnliche LH-Werte haben, als auch räumlich nah beieinander liegen.

Im optionalen dritten und letzten Clusteringschritt wird hierarchisch geclustert. Hierbei wird für jeden Cluster die paarweise Nähe zu jedem anderen Cluster errechnet. Anschließend werden hierarchisch immer die zwei Cluster, die sich am nächsten sind, zu einem gemerged, solange bis nur noch ein Cluster existiert. Hierbei speichert das Programm jeweils welche Cluster wann miteinander gemerged wurden. Der Benutzer kann im Anschluss entscheiden wie viel Cluster er haben möchte. Abhängig davon, wird das hierarchische Clustern umgekehrt und die Cluster werden wieder getrennt, bis die gewünschte Anzahl an Clustern erreicht ist.

3. Methods

Im Paper von Hong [19] wird ein Approximationsbasiertes Verfahren zur Berechnung von Gradienten eines Volumens vorgestellt.

Hierbei ist zu beachten, dass der Gradient nicht für einen Voxel direkt berechnet werden kann. Der Gradient liegt im Falle eines dreidimensionalen Volumens im Zentrum eines Würfels, der von 4 benachbarten Voxeln aufgepasst wird. In Hong's Verfahren wird zur Berechnung die lokale 4x4x4 Nachbarschaft hinzugezogen.



Die Funktionen für die Intensitätswerte wird im Paper mit: $f(x, y, z) = Ax^2 + By^2 + Cz^2 + 2Fyz + 2Gzx + 2Hxy + 2Ix + 2Jy + 2Kz + D$ approximiert. Den dreidimensionalen Gradientenvektor n erhält man, indem man die Funktion ableitet: $n = (Ax + Gz + Hy + I, By + Fz + Hx + J, Cz + Fy + Gx + K)$.

Um den Gradienten zu Berechnen müssen die Parameter A,B,C,E,F,G,H,I,J,K berechnet werden. Dies geschieht mithilfe der Methode der kleinsten Quadrate.


richtig
bild
zitieren
u. evtl
kleiner

4. **Concept**

...

5. ImplementationImplementation

...



6. Results

...

| Object | Speed [cm/s] | Inner LR [cm] | Inner UR [cm] |
|----------------|------------------|-------------------|-------------------|
| <i>Pitcher</i> | real | n/a | 5.65 |
| | 4.60 | 3.71 ± 0.67 | 5.09 ± 2.23 |
| | 10.64 | 3.55 ± 0.57 | 6.14 ± 0.69 |
| Cookie O | real | 7.55 | 7.55 |
| | 4.60 | 6.98 ± 0.27 | 6.98 ± 0.27 |
| | 10.64 | 6.77 ± 0.26 | 6.77 ± 0.26 |

Table 1: Estimated objects inner parameters on different speeds compared to real sizes of the object. Inner LR stands for lower inner radius of the object and Inner UR for upper radius. The real value of inner lower radius for object *Pitcher* is very hard to be determined precisely, therefore the real value is marked with n/a .

7. Discussion

...

8. Conclusion

...

References

- [1] S. Lan, L. Wang, Y. Song, Y.-p. Wang, L. Yao, K. Sun, B. Xia, and Z. Xu, “Improving separability of structures with similar attributes in 2d transfer function design,” *IEEE transactions on visualization and computer graphics*, vol. 23, no. 5, pp. 1546–1560, 2017.
- [2] S. Wesarg and M. Kirschner, “Structure size enhanced histogram,” in *Bildverarbeitung für die Medizin 2009*. Springer, 2009, pp. 16–20.
- [3] S. Wesarg, M. Kirschner, and M. F. Khan, “2d histogram based volume visualization: combining intensity and size of anatomical structures,” *International journal of computer assisted radiology and surgery*, vol. 5, no. 6, pp. 655–666, 2010.
- [4] R. Huang and K.-L. Ma, “Rgvis: Region growing based techniques for volume visualization,” in *null*. IEEE, 2003, p. 355.
- [5] C. Correa and K.-L. Ma, “Size-based transfer functions: A new volume exploration technique,” *IEEE transactions on visualization and computer graphics*, vol. 14, no. 6, pp. 1380–1387, 2008.
- [6] —, “The occlusion spectrum for volume classification and visualization,” *IEEE Transactions on Visualization and Computer Graphics*, vol. 15, no. 6, pp. 1465–1472, 2009.
- [7] C. D. Correa and K.-L. Ma, “Visibility-driven transfer functions,” in *Visualization Symposium, 2009. PacificVis’ 09. IEEE Pacific*. IEEE, 2009, pp. 177–184.
- [8] Y. Wu and H. Qu, “Interactive transfer function design based on editing direct volume rendered images,” *IEEE Transactions on Visualization and Computer Graphics*, vol. 13, no. 5, pp. 1027–1040, 2007.
- [9] C. D. Correa and K.-L. Ma, “Visibility histograms and visibility-driven transfer functions,” *IEEE Transactions on Visualization and Computer Graphics*, vol. 17, no. 2, pp. 192–204, 2011.
- [10] H.-L. J. Chen, F. F. Samavati, M. C. Sousa, and J. R. Mitchell, “Sketch-based volumetric seeded region growing,” in *SBM*, 2006, pp. 123–129.
- [11] F.-Y. Tzeng, E. B. Lum, and K.-L. Ma, “An intelligent system approach to higher-dimensional classification of volume data,” *IEEE Transactions on visualization and computer graphics*, vol. 11, no. 3, pp. 273–284, 2005.
- [12] K. P. Soundararajan and T. Schultz, “Learning probabilistic transfer functions: A comparative study of classifiers,” in *Computer Graphics Forum*, vol. 34, no. 3. Wiley Online Library, 2015, pp. 111–120.
- [13] S. Fang, T. Biddlecome, and M. Tuceryan, “Image-based transfer function design for data exploration in volume visualization,” in *Visualization’98. Proceedings*. IEEE, 1998, pp. 319–326.
- [14] B. Reitinger, C. Zach, A. Bornik, and R. Beichel, “User-centric transfer function specification in augmented reality,” 2004.

- [15] P. Sereda, A. V. Bartoli, I. W. Serlie, and F. A. Gerritsen, “Visualization of boundaries in volumetric data sets using lh histograms,” *IEEE Transactions on Visualization and Computer Graphics*, vol. 12, no. 2, pp. 208–218, 2006.
- [16] I. Serlie, R. Truyen, J. Florie, F. Post, L. van Vliet, and F. Vos, “Computed cleansing for virtual colonoscopy using a three-material transition model,” in *International Conference on Medical Image Computing and Computer-Assisted Intervention*. Springer, 2003, pp. 175–183.
- [17] P. Sereda, A. Vilanova, and F. A. Gerritsen, “Automating transfer function design for volume rendering using hierarchical clustering of material boundaries.” in *EuroVis*, 2006, pp. 243–250.
- [18] B. P. Nguyen, W.-L. Tay, C.-K. Chui, and S.-H. Ong, “A clustering-based system to automate transfer function design for medical image visualization,” *The Visual Computer*, vol. 28, no. 2, pp. 181–191, 2012.
- [19] D.-h. Hong, G.-m. Ning, T. Zhao, M. Zhang, and X. Zheng, “Method of normal estimation based on approximation for visualization,” *Journal of Electronic Imaging*, vol. 12, no. 3, pp. 470–478, 2003.

Appendix

A. First Appendix Section

ein Bild

Figure A.1: A figure

...